

## 1.MCMC简介


马尔可夫链蒙特卡罗(Markov Chain Monte Carlo,MCMC)是一种随机采样方法,在机器学习、深度学习及自然语言处理等领域都有广泛的应用,是很多复杂算法求解的基础,例如受限玻尔兹曼机(RBM)便是用MCMC来做一些复杂算法的近似求解。在具体讲解什么是MCMC之前,我们先看看MCMC可以解决什么样的问题,为什么需要MCMC方法。

## 2. 为什么需要MCMC?

假如我们需要对一维随机变量 $X$ 进行随机采样, $X$ 的样本空间是 $\{1, 2, 3\}$ ,概率分别是 $\{\frac{1}{2}, \frac{1}{4}, \frac{1}{4}\}$ 。那么我们只需要根据各离散值的概率大小对 $[0,1]$ 区间进行等比例划分,例如划分为 $[0,0.5],[0.5,0.75],[0.75,1]$ 三个区间,然后通过计算机产生 $[0,1]$ 之间的伪随机数,根据伪随机数的落点便可完成采样。下面问题变得复杂一些,假如 $X$ 是连续分布,概率密度函数(PDF)是 $f(X)$ ,那么如何采样呢。


你肯定会想到累积分布函数(CDF),表达式为 $P(x) = \int_{-\infty}^x f(x)dx$ 。然后在 $[0,1]$ 间随机生成一个数 $a$ ,求使得 $x = CDF^{-1}(a)$ ,此时便可得到一个采样结果。例如以高斯分布为例进行采样,高斯分布的概率密度函数如下所示

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-u)^2}{2\sigma^2}\right)$$



累积分布函数如下所示

$$P(x) = \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^x \exp\left(-\frac{(x-u)^2}{2\sigma^2}\right) dx$$




首先通过均匀分布 $U(0,1)$ 得到一个值 $a$ ，然后通过累积分布函数的反函数，计算得到满足 $CDF^{-1}(a) = x$ 的 $x$ ， $x$ 便是我们需要的采样样本。

上面针对连续分布采样有两个假设前提：一是概率密度函数可积；二是累积分布函数有反函数。但是上述假设前提不成立怎么办？此时便需要用到下面介绍的MCMC。

### 3.蒙特卡罗方法

我们首先介绍MCMC中的蒙特卡罗(Monte Carlo)方法，蒙特卡罗是一种随机模拟的方法，最初的蒙特卡罗方法是用来求解积分问题，比如

$$\theta = \int_a^b f(x)dx$$



如果我们很难求解出 $f(x)$ 的原函数，那么这个积分便很难求解，此时我们便利用蒙特卡罗方法来模拟求解近似值，但如何模拟呢？针对上述积分，一个简单的近似求解方法是在 $[a,b]$ 之间随机的采样一个点，比如 $x_0$ ，然后用 $f(x_0)$ 代表在 $[a,b]$ 区间上所有 $f(x)$ 的值，那么上面定积分的近似值便为

$$(b-a)f(x_0)$$

当然，用一个值来代表 $[a,b]$ 上面所有 $f(x)$ 的值，这个结果不太准确。因此我们可以采样 $[a,b]$ 区间的 $n$ 个值 $x_0, x_1, x_3, \dots, x_{n-1}$ ，用他们的均值来代表 $[a,b]$ 区间上所有 $f(x)$ 的值，这样定积分求解的近似值为

$$\frac{b-a}{n} \sum_{i=0}^{n-1} f(x_i)$$

虽然上面的方法可以求解近似值，但它隐含一个假设，即 $x$ 在 $[a,b]$ 之间是均匀分布的。而大多数情况下， $x$ 在 $[a,b]$ 之间不是均匀分布的，如果继续用上面的方法，模拟求出的结果很可能和结果相差甚远，那怎么解决这个问题呢？如果我们可以得到 $x$ 在 $[a,b]$ 的概率分布函数 $p(x)$ ，那么我们的定积分求和可以转换为

$$\theta = \int_a^b f(x)dx = \int_a^b \frac{f(x)}{p(x)} p(x)dx \approx \frac{1}{n} \sum_{i=0}^{n-1} \frac{f(x_i)}{p(x_i)}$$

上述是蒙特卡罗连续函数的形式，当然在离散时一样成立。可以看出，最上面我们假设 $x$ 在 $[a,b]$ 之间时均匀分布的时候 $p(x_i) = \frac{1}{b-a}$ ，带入我们有概率分布的蒙特卡罗积分，可以得到

$$\frac{1}{n} \sum_{i=0}^{n-1} \frac{f(x_i)}{1/(b-a)} = \frac{b-a}{n} \sum_{i=0}^{n-1} f(x_i)$$

也就是说，最上面的均匀分布可以作为一般概率分布函数 $p(x)$ 在均匀分布时候的特例，那么现在问题便转换为如何求出 $x$ 的分布 $p(x)$ 对应的若干个样本上来。

## 4. 概率分布采样

上面讲到蒙特卡罗方法的关键是得到 $x$ 的概率分布 $p(x)$ ，如果求出了 $x$ 的概率分布，便可以基于这个概率分布去采样 $n$ 个 $x$ 的样本集，然后带入蒙特卡罗求和的方程式便可以求解。当然，上面的关键问题还没有解决，即如何基于概率分布去采样 $n$ 个 $x$ 的样本集。

对于常见的均匀分布 $\text{uniform}(0,1)$ 是很容易采集样本的，一般通过线性同余发生器便可以很方便的生成 $(0,1)$ 之间的伪随机数样本。对于常见的概率分布，无论是离散的分布还是连续的分布，都可以通过 $\text{uniform}(0,1)$ 的样本转换得到。比如二维正态分布的样本 $(Z_1, Z_2)$ ，可以通过独立采样得到 $\text{uniform}(0,1)$ 样本对 $(X_1, X_2)$ 进行转换得到，转换方程式如下所示


$$Z_1 = \sqrt{-2\ln X_1} \cos(2\pi X_2)$$

$$Z_2 = \sqrt{-2\ln X_1} \sin(2\pi X_2)$$

其他的一些常见的连续分布，比如 $t$ 分布, $F$ 分布,Beta分布,Gamma分布等，都可以通过类似的方式从 $\text{uniform}(0,1)$ 得到的样本转换得到。不过很多时候，我们 $x$ 的概率分布不是常见的分布，这意味着我们无法方便的得到这些概率分布的样本集，那这个问题怎么解决呢？

## 5. 接受-拒绝采样

对于概率分布不是常见的分布，一个可行的方法是采用接受-拒绝采样来得到该分布的样本。既然 $p(x)$ 太复杂在程序中没法直接采样，那么我们设定一个可采样的分布 $q(x)$ ，比如高斯分布，然后按照一定的方法拒绝某些样本，以达到接近 $p(x)$ 分布的目的，其中 $q(x)$ 叫做建议分布(proposal distribution)。



具体采样过程为，设定一个方便采样的常用概率分布 $q(x)$ 以及一个常量 $k$ ，使得 $p(x)$ 总在 $kq(x)$ 的下方，即 $k * q(z) \geq \tilde{p}(z)$ 。

首先从建议分布 $q(z)$ 中采样得到样本 $z$ ，然后从均匀分布 $U(0,1)$ 中采样得到样本 $u$ ，如果 $u \leq \frac{\tilde{p}(z)}{k * q(z)}$ ，则接受此次采样，否则拒绝此次采样。整个过程中，我们通过一系列接受-拒绝采样的决策来达到用 $q(x)$ 模拟 $p(x)$ 概率分布的目的。

## 6. 蒙特卡罗方法总结

使用接受-拒绝采样，可以解决一些概率分布不是常见分布的情况，然后得到采样集，最后用蒙特卡罗方法求和。但是接受-拒绝采样只能部分满足我们的情况，在很多时候我们还是很难得到概率分布的样本集，比如

- 对于一些二维分布 $(x,y)$ ，有些时候只能得到条件概率分布 $p(x|y)$ 和 $p(y|x)$ ，却很难得到二维分布 $p(x,y)$ ，这时便无法采用接受拒绝采样得到其样本集。
- 对于一些高维的复杂分布 $p(x_1,x_2,x_3,\dots,x_n)$ ，得到合适的 $q(x)$ 和 $k$ 非常困难。

从上面可以看出，要将蒙特卡罗方法作为通用的采样模拟求和方法，必须解决如何方便得到**各种复杂概率分布的对应采样样本**的问题。下篇文章，我们将通过介绍马尔可夫链，来帮助我们找到这些复杂概率分布所对应的采样样本集。


## 7.推广

更多内容请关注公众号**谓之小一**，如有疑问可在公众号后台提问，随时回答，欢迎关注，内容转载请注明出处。

「谓之小一」希望提供给读者别处看不到的内容，关于互联网、数据挖掘、机器学习、书籍、生活.....

- 知乎：@谓之小一
- 公众号：@谓之小一
- GitHub：@weizhixiaoyi
- 技术博客：<https://weizhixiaoyi.com>





请之小一

长按关注微信公众号

由锤子便签发送 via Smartisan Notes