

**奇异值分解(Singular Value Decomposition, SVD)**是在机器学习领域广泛应用的算法，不光可以用于降维算法中的特征分解，还可以用于推荐系统，以及自然语言处理等领域，是很多机器学习算法的基石。本篇文章对SVD原理做主要讲解，在学习之前，确保你已经熟悉线性代数中的基本知识，包括特征值、特征向量、相似矩阵相关知识点。如果不太熟悉的话，推荐阅读如下两篇文章，[如何理解矩阵特征值？知乎马同学的回答](#)和[如何理解相似矩阵？马同学高等数学](#)，读完之后再读本篇文章会有很大帮助。

## 1. 回顾特征值和特征向量

我们首先回顾下特征值和特征向量的定义，如下所示。其中A是一个 $n \times n$ 的矩阵，x是一个n维向量，则我们说 $\lambda$ 是矩阵A的一个特征值，x是矩阵A的特征值 $\lambda$ 所对应的特征向量。但是求出特征值和特征向量有什么好处呢？

$$Ax = \lambda x$$

求出了矩阵A的n个特征值 $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$ ，以及这n个特征值所对应的特征向量 $w_1, w_2, \dots, w_n$ ，如果这n个特征值线性无关，那么矩阵A就可以用下式的特征分解表示

$$A = W \Sigma W^{-1}$$

其中 $\Sigma$ 是以这n个特征值为主对角线的 $n \times n$ 维矩阵，W是这n个特征向量所组成的 $n \times n$ 维矩阵。一般我们会把W的这n个特征向量标准化，即满足 $\|w_i\|_2 = 1$ ，或者说 $w_i^T w_i = 1$ ，此时W的n个特征向量为标准正交基，满足 $W^T W = I$ ，即 $W^T = W^{-1}$ ，也就是说W为酉矩阵。这样我们的特征分解便可写作

$$A = W \Sigma W^T$$

上面矩阵能够进行特征分解，需要满足矩阵A必须为方阵。那么如果A不是方阵，即行和列不相同，我们还可以进行矩阵分解吗？

## 2. 奇异值分解(SVD)


当矩阵A不是方阵时，可以用奇异值进行分解，假设我们的的矩阵A是一个 $m \times n$ 的矩阵，那么我们定义矩阵A的SVD为

$$A = U \Sigma V^T$$

其中U是一个 $m \times m$ 的矩阵， $\Sigma$ 是一个 $m \times n$ 的矩阵，除了主对角线上的元素以外全为0，主对角线上的每个元素都称为奇异值，V是一个 $n \times n$ 的矩阵。U和V都是酉矩阵，即满足

$$\begin{aligned} U^T U &= I \\ V^T V &= I \end{aligned}$$

下图可以形象的表示出上述SVD的定义，但我们如何求出SVD分解后的U,  $\Sigma$ , V这三个矩阵呢？



如果我们将A的转置和A做矩阵乘法，那么会得到 $n \times n$ 的一个方阵 $A^T A$ 。既然 $A^T A$ 是方阵，那么我们就可以进行特征分解，得到的特征值和特征向量满足下式

$$(A^T A)v_i = \lambda_i v_i$$

这样我们就可以得到矩阵 $A^T A$ 的 $n$ 个特征值和对应的 $n$ 个特征向量 $v$ 。将 $A^T A$ 的所有特征向量组成一个 $n \times n$ 的矩阵 $V$ ，就是SVD公式里面的 $V$ 矩阵，一般我们将 $V$ 中的每个特征向量叫做A的右奇异向量。

同样，如果我们将A和A的转置做矩阵乘法，那么会得到 $m \times m$ 的一个方阵 $AA^T$ 。因为 $AA^T$ 是方阵，那么我们就可以进行特征分解，得到的特征值和特征向量满足下式

$$(AA^T)u_i = \lambda_i u_i$$

这样我们就可以得到矩阵 $AA^T$ 的 $m$ 个特征值和对应的 $m$ 个特征向量 $u$ 。将 $AA^T$ 的所有特征向量组成一个 $m \times m$ 的矩阵 $U$ ，就是SVD公式里面的 $U$ 矩阵，一般我们将 $U$ 中的每个特征向量叫做A的左奇异向量。

$U$ 和 $V$ 都已经求出，现在只有奇异值矩阵 $\Sigma$ 没有求出。由于 $\Sigma$ 除了对角线上是奇异值，其他位置都是0，因此我们只需要求出每个奇异值 $\sigma$ 就可以了。我们注意到

$$\begin{aligned} A &= U\Sigma V^T \\ AV &= U\Sigma V^T V \\ AV &= U\Sigma \\ Av_i &= u_i \sigma_i \\ \sigma_i &= \frac{Av_i}{u_i} \end{aligned}$$

通过上式，我们便可以求出每个奇异值，进而求出奇异值矩阵 $\Sigma$ 。

上面还有一个问题没有细讲，就是我们说 $A^T A$ 的特征向量组成的就是SVD中的 $V$ 矩阵， $AA^T$ 的特征向量就是SVD的 $U$ 矩阵，为什么呢？下面我们做简短证明。

$$\begin{aligned} A &= U\Sigma V^T \\ A^T &= V\Sigma^T U^T \\ A^T A &= V\Sigma^T U^T U\Sigma V^T = V\Sigma^2 V^T \end{aligned}$$

上式证明中使用到 $U^T U = I, \Sigma^T \Sigma = \Sigma^2$ ，可以看出 $A^T A$ 的特征向量，的确就是SVD中的 $V$ 矩阵。类似的方法同样可以得到 $AA^T$ 的特征向量，就是SVD中的 $U$ 矩阵。进一步我们还可以看出特征值矩阵等于奇异值矩阵的平方，也就是特征值和奇异值满足如下关系

$$\sigma_i = \sqrt{\lambda_i}$$

这也就是说，我们不仅可以通过用 $\sigma_i = \frac{Av_i}{u_i}$ 来计算奇异值，也可以通过求出 $A^T A$ 的特征值，然后取平方根得到奇异值。

### 3. SVD示例

下面我们通过一个简单例子来说明矩阵式如何进行奇异值分解的，假设矩阵A为

$$A = \begin{pmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{pmatrix}$$

然后求出 $A^T A$ 和 $AA^T$

$$A^T A = \begin{pmatrix} 0 & 1 & 1 \\ 1 & 1 & 0 \end{pmatrix} \begin{pmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

$$AA^T = \begin{pmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 0 & 1 & 1 \\ 1 & 1 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 1 \end{pmatrix}$$

进而求出 $A^T A$ 的特征值和特征向量

$$\lambda_1 = 3; v_1 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}$$

$$\lambda_2 = 1; v_2 = \begin{pmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}$$

求出 $AA^T$ 的特征值和特征向量

$$\lambda_1 = 3; u_1 = \begin{pmatrix} \frac{1}{\sqrt{6}} \\ \frac{2}{\sqrt{6}} \\ \frac{1}{\sqrt{6}} \end{pmatrix}$$

$$\lambda_2 = 1; u_2 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ 0 \\ -\frac{1}{\sqrt{2}} \end{pmatrix}$$

$$\lambda_3 = 0; u_3 = \begin{pmatrix} \frac{1}{\sqrt{3}} \\ -\frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{3}} \end{pmatrix}$$

利用 $Av_i = \sigma_i u_i, i = 1, 2$ 求解奇异值

$$\begin{pmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix} = \sigma_1 \begin{pmatrix} \frac{1}{\sqrt{6}} \\ \frac{2}{\sqrt{6}} \\ \frac{1}{\sqrt{6}} \end{pmatrix} \Rightarrow \sigma_1 = \sqrt{3}$$

$$\begin{pmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix} = \sigma_2 \begin{pmatrix} \frac{1}{\sqrt{2}} \\ 0 \\ -\frac{1}{\sqrt{2}} \end{pmatrix} \Rightarrow \sigma_2 = 1$$

当然，我们也可以利用 $\sigma_i = \sqrt{\lambda_i}$ 直接求出奇异值 $\sqrt{3}$ 和1。最终得到A的奇异值分解为


$$A = U\Sigma V^T = \begin{pmatrix} \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ \frac{2}{\sqrt{6}} & 0 & -\frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \end{pmatrix} \begin{pmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix}$$

## 4. SVD性质

对于SVD有哪些重要的性质值得我们注意呢？对于奇异值，它跟特征分解中的特征值类似，在奇异值矩阵中也是按照从大到小排列，而且奇异值的减少特别的快，在很多情况下，前10%甚至1%的奇异值的和就占了全部奇异值之和的99%以上的比例。也就是说，我们可以用最大的k个奇异值和对应的左右奇异向量来近似描述矩阵，即

$$A_{m \times n} = U_{m \times m} \Sigma_{m \times n} V_{n \times n}^T \approx U_{m \times k} \Sigma_{k \times k} V_{k \times n}^T$$

其中k要比n小很多，也就是一个大的矩阵A可以用三个小的矩阵 $U_{m \times k}$ ,  $\Sigma_{k \times k}$ ,  $V_{k \times n}^T$ 来表示。如下图所示，现在矩阵A只需要灰色部分的三个小矩阵就可以近似描述。



由于这个重要的性质，因此SVD可以用于PCA降维，用来做数据压缩和去噪。也可以用于推荐算法，将用户和喜好对应的矩阵做特征分解，进而得到隐含的用户需求来做推荐。同时也可以用于NLP之中的算法，比如潜在语义索引(LSI)。

## 5. SVD在PCA之中的应用

在[机器学习降维之主成分分析\(PCA\)](#)之中，我们讲到PCA降维时，需要找到样本协方差矩阵 $X^T X$ 最大的d个特征向量，然后用着最大的d个特征向量组成的矩阵来做低维投影降维。可以看出，在这个过程中需要先求出协方差矩阵 $X^T X$ ，当样本数多、样本特征数也多的时候，比如10000\*10000的矩阵，这个计算量是很大的。

注意到SVD也可以求出协方差矩阵 $X^T X$ 最大的d个特征向量组成的矩阵，但是SVD有个好处，就是可以不求出协方差矩阵 $X^T X$ ，也能通过某些算法求出右奇异矩阵 $V$ ，比如

<https://arxiv.org/abs/0909.4061>。也就是说，PCA算法可以不用做特征分解，而是用SVD来进行完成。

另一方面，PCA仅仅使用了SVD的右奇异矩阵，没有使用左奇异矩阵，那么左奇异矩阵有什么用呢？假如我们的样本是 $m \times n$ 的矩阵 $X$ ，如果通过SVD找到矩阵 $X X^T$ 最大的d个特征向量组成的 $m \times d$ 的矩阵 $U$ ，则我们进行如下处理

$$X'_{d \times n} = U_{d \times m}^T X_{m \times n}$$

可以得到一个 $d \times n$ 的矩阵 $X'$ ，这个矩阵和我们原来的 $m \times n$ 维样本矩阵 $X$ 相比，行数从 $m$ 减到了 $d$ ，可见对行数进行了压缩。也就是说，左奇异矩阵可以用于行数的压缩，右奇异矩阵可以用于列数压缩，即特征降维。

## 6. SVD算法总结

SVD作为一个很基本的算法，在很多机器学习算法中都有它的身影，特别是在现在的大数据时代，由于SVD可以实现并行化，因此更是大展身手。当然，SVD的缺点是分解出的矩阵解释性往往不强，不过这不影响它的使用。

## 7. 推广

更多内容请关注公众号谓之小一，若有疑问可在公众号后台留言，随时回答，欢迎关注，内容转载请注明出处。

「谓之小一」希望提供给读者别处看不到的内容，关于互联网、数据挖掘、机器学习、书籍、生活.....

- 知乎：@谓之小一
- 公众号：@谓之小一
- GitHub：@weizhixiaoyi

- 技术博客: <https://weizhixiaoyi.com>



请之小一

长按关注微信公众号

由锤子便签发送 via Smartisan Notes

参考

[刘建平Pinard-奇异值分解\(SVD\)原理转载降维中的应用](#)